هوش محاسباتی
تمرین عملی | دسته‌بندی خطی داده‌های وزن و قد با مرز تصمیم

هدف تمرین

در این تمرین قرار است با یک مسئله ساده اما واقعی از **دسته‌بندی دودویی** و **مرز تصمیم خطی** کار کنید. فرض کنید برای تعدادی مرد، دو ویژگی **وزن** و **قد** در اختیار داریم و بر اساس ارزیابی انجام‌شده، هر فرد در یکی از دو گروه زیر قرار گرفته است:

- **متناسب**: برچسب $+1$
- **نامتناسب**: برچسب -1

هدف این است که با استفاده از یک خط تصمیم، تا حد امکان این دو گروه را از یکدیگر جدا کنیم. نکته مهم این است که داده‌های این تمرین **کاملاً خطی جداپذیر نیستند**. بنابراین انتظار نداریم بتوانیم خطی پیدا کنیم که تمام نمونه‌های آموزشی را بدون خطا دسته‌بندی کند.

۱. داده‌های آموزشی

داده‌های زیر را دقیقاً در ابتدای نوت‌بوک خود وارد کنید. واحد قد **سانتی‌متر** و واحد وزن **کیلوگرم** است.

شماره	وزن (kg)	قد (cm)	برچسب	
۱	۵۵	۱۶۵	$+1$	متناسب
۲	۶۵	۱۷۰	$+1$	متناسب
۳	۷۲	۱۷۵	$+1$	متناسب
۴	۷۸	۱۸۰	$+1$	متناسب
۵	۸۰	۱۶۰	-1	نامتناسب
۶	۸۷	۱۶۴	-1	نامتناسب
۷	۹۵	۱۷۲	-1	نامتناسب
۸	۱۰۰	۱۸۵	-1	نامتناسب
۹	۸۰	۱۷۵	$+1$	متناسب
۱۰	۷۰	۱۸۰	-1	نامتناسب

توجه: برچسب‌ها در این تمرین برچسب‌های آموزشی هستند و قرار نیست شما یک معیار پزشکی واقعی برای تعیین تناسب اندام بسازید. هدف اصلی تمرین، مطالعه رفتار یک دسته‌بند خطی در حضور داده‌هایی است که کاملاً خطی جداپذیر نیستند.

۲. ساخت نوت‌بوک

تمرین را به‌صورت یک **Notebook Jupyter با زبان Python** انجام دهید. نوت‌بوک باید شامل سلول‌های متنی (Markdown) برای توضیح مراحل و سلول‌های کدنویسی برای محاسبات و رسم نمودارها باشد.

برای رسم نمودار می‌توانید از matplotlib و برای کار با آرایه‌ها از numpy استفاده کنید. استفاده از کتابخانه‌های آماده دسته‌بندی مانند scikit-learn برای ساخت مدل اصلی این تمرین مجاز نیست؛ هدف این است که مفهوم مرز تصمیم و خطا را خودتان پیاده‌سازی کنید.

۳. رسم اولیه داده‌ها

در اولین بخش عملی نوت‌بوک:

۱. وزن را روی محور افقی و قد را روی محور عمودی قرار دهید.

۲. نمونه‌های «متناسب» را با رنگ **سبز** رسم کنید.

۳. نمونه‌های «نامتناسب» را با رنگ **زرد** رسم کنید.

۴. برای هر گروه، راهنمای مناسب (legend) قرار دهید.

۵. عنوان و نام محورهای نمودار را مشخص کنید.

سپس در یک سلول Markdown به‌صورت کوتاه پاسخ دهید:

آیا با نگاه کردن به نمودار می‌توان یک خط مستقیم پیدا کرد که تمام نمونه‌های متناسب را در یک طرف و تمام نمونه‌های نامتناسب را در طرف دیگر قرار دهد؟ دلیل خود را توضیح دهید.

۴. تعریف مرز تصمیم

یک تابع تصمیم خطی به شکل زیر در نظر بگیرید:

$$g(x) = w_0 + w_1 x_1 + w_2 x_2$$

که در آن:

- x_1 وزن فرد است.
- x_2 قد فرد است.
- w_0 وزن بایاس یا عرض از مبدأ است.
- w_1 وزن مربوط به ویژگی وزن است.
- w_2 وزن مربوط به ویژگی قد است.

مرز تصمیم زمانی ایجاد می‌شود که:

$$w_0 + w_1 x_1 + w_2 x_2 = 0$$

بنابراین در صفحه وزن—قد، مرز تصمیم یک خط است.
در نوت‌بوک تابعی بنویسید که با دریافت w_0, w_1, w_2 مقدار $g(x)$ را برای یک نمونه محاسبه کند.
سپس یک تابع دسته‌بندی تعریف کنید؛ برای مثال:

$$\hat{y} = \begin{cases} +1 & g(x) \geq 0 \\ -1 & g(x) < 0 \end{cases}$$

۵. رسم خط جداکننده

مقادیر اولیه‌ای برای سه وزن w_0, w_1, w_2 انتخاب کنید. سپس خط

$$w_0 + w_1 x_1 + w_2 x_2 = 0$$

را روی همان نمودار داده‌ها رسم کنید.
نوت‌بوک باید به‌گونه‌ای نوشته شود که با تغییر سه وزن، خط نیز به‌صورت خودکار جابه‌جا شود.
نکته: اگر $w_2 \neq 0$ باشد، می‌توان خط را برای رسم به صورت زیر نوشت:

$$x_2 = -\frac{w_0 + w_1 x_1}{w_2}$$

در کنار خط، نقاط داده نیز باید همچنان دیده شوند.

۶. محاسبه خطای آموزش

برای هر یک از ۱۰ نمونه، مقدار $\hat{y}$ را با برچسب واقعی y مقایسه کنید.
خطای آموزش را به‌صورت تعداد نمونه‌های اشتباه تعریف کنید:

$$E = \sum_{i=1}^{10} I(\hat{y}_i \neq y_i)$$

که در آن I تابع شاخص است و اگر پیش‌بینی اشتباه باشد مقدار ۱ و در غیر این صورت مقدار ۰ دارد.
در نوت‌بوک:

۱. پیش‌بینی تمام ۱۰ نمونه را نمایش دهید.

۲. تعداد خطاها را محاسبه کنید.

۳. نرخ خطای آموزش را نیز محاسبه کنید:

$$ErrorRate = \frac{E}{10}$$

۴. نمونه‌هایی را که اشتباه دسته‌بندی شده‌اند مشخص کنید.

۷. کاهش خطا با تغییر وزن‌ها

اکنون بخش اصلی تمرین را انجام دهید.
سه وزن w_0, w_1, w_2 را به‌صورت دستی تغییر دهید و هر بار:

- خط جداکننده را رسم کنید؛
- خطای آموزش را محاسبه کنید؛
- تعداد نمونه‌های اشتباه را مشخص کنید.

حداقل **۵ مجموعه متفاوت از وزن‌ها** را امتحان کنید و نتیجه را در جدولی مانند جدول زیر ثبت کنید:

آزمایش	w_0	w_1	w_2	خطای آموزش
۱				
۲				
۳				
۴				
۵				

در پایان بهترین مجموعه وزن‌هایی را که پیدا کرده‌اید گزارش کنید.

۸. چرا خطا به صفر نمی‌رسد؟

با توجه به نمودار و نتایج آزمایش‌های خود، توضیح دهید چرا نمی‌توان انتظار داشت خطای آموزش با یک خط مستقیم به صفر برسد.
به‌طور مشخص به این سؤال پاسخ دهید:

اگر داده‌ها کاملاً خطی جداپذیر نباشند، آیا تغییر هوشمندانه وزن‌ها می‌تواند خطای آموزش را دقیقاً صفر کند؟

نکته مهم: در این مجموعه داده، دست‌کم یک نمونه باید با هر مرز خطی ناگزیر در سمت نادرست قرار بگیرد. بنابراین اگر بهترین خط شما هنوز یک خطای محدود دارد، این موضوع لزوماً به معنی بد بودن روش شما نیست؛ ممکن است محدودیت از خود داده‌ها ناشی شود.

۹. یک روش ساده برای جست‌وجوی وزن‌های بهتر

علاوه بر تغییر کاملاً دستی، یک روش ساده برای جست‌وجوی وزن‌ها پیاده‌سازی کنید.
برای مثال، می‌توانید برای w_0, w_1, w_2 مقادیر مختلفی را امتحان کنید و مجموعه‌ای را نگه دارید که کمترین خطای آموزش را ایجاد می‌کند.
لازم نیست از الگوریتم‌های آماده یادگیری ماشین استفاده کنید. هدف این بخش، درک رابطه میان:

خطا ⟵ پیش‌بینی ⟵ مرز تصمیم ⟵ وزن‌ها

است.
در صورت استفاده از جست‌وجوی شبکه‌ای (Grid Search)، محدوده و گام جست‌وجوی خود را در نوت‌بوک توضیح دهید.

۱۰. آزمون با داده‌های جدید

پس از انتخاب بهترین وزن‌های خود، مدل را روی چهار نمونه‌ای که در آموزش استفاده نشده‌اند آزمایش کنید.

شماره	وزن (kg)	قد (cm)	برچسب واقعی	
۱۱	۶۰	۱۶۸	$+1$	متناسب
۱۲	۸۸	۱۷۰	-1	نامتناسب
۱۳	۷۲	۱۸۲	$+1$	متناسب
۱۴	۹۲	۱۸۰	-1	نامتناسب

برای هر نمونه:

۱. مقدار $g(x)$ را محاسبه کنید.

۲. برچسب پیش‌بینی‌شده را به دست آورید.

۳. آن را با برچسب واقعی مقایسه کنید.

۴. در نهایت خطای آزمون را گزارش کنید.

۱۱. مقایسه خطای آموزش و آزمون

در پایان، دو مقدار زیر را گزارش کنید:

$$Training\ Error \qquad Test\ Error$$

سپس در چند جمله توضیح دهید:

- آیا بهترین وزن‌های پیدا شده روی داده‌های آموزشی عملکرد بهتری دارند یا روی داده‌های آزمون؟
- آیا کمینه کردن خطای آموزش الزاماً به معنی بهترین عملکرد روی داده‌های جدید است؟
- اگر وزن‌ها را بیش از حد بر اساس داده‌های آموزشی تنظیم کنیم، چه مشکلی ممکن است ایجاد شود؟

۱۲. بخش اختیاری: مشاهده اثر هر ویژگی

یک بار مرز تصمیم را با وزن‌های مختلف w_1 و w_2 رسم کنید و بررسی کنید که تغییر هرکدام چه اثری بر شیب خط دارد.
به سؤال‌های زیر پاسخ دهید:

- افزایش w_1 چه اثری بر خط تصمیم دارد؟
- تغییر w_2 چه اثری بر شیب خط دارد؟
- w_0 چه نقشی در جابه‌جایی خط دارد؟
- اگر $w_0 = 0$ باشد، خط تصمیم از کجا عبور می‌کند؟

۱۳. بخش اختیاری: نمایش نواحی تصمیم

نمودار را طوری توسعه دهید که علاوه بر نقاط و خط تصمیم، دو ناحیه مربوط به پیش‌بینی $+1$ و -1 نیز با دو رنگ بسیار کم‌رنگ نمایش داده شوند.

هدف این بخش آن است که مشخص شود خط تصمیم فقط یک خط روی نمودار نیست، بلکه صفحه را به دو ناحیه تصمیم تقسیم می‌کند.

۱۴. آنچه باید تحویل دهید

یک فایل Jupyter Notebook با پسوند ipynb. تحویل دهید که حداقل شامل موارد زیر باشد:

۱. ورود و نمایش داده‌های آموزشی؛

۲. نمودار اولیه با متناسب‌های سبز و نامتناسب‌های زرد؛

۳. تعریف تابع تصمیم با w_0, w_1, w_2؛

۴. رسم خط تصمیم؛

۵. محاسبه خطای آموزش؛

۶. حداقل پنج آزمایش با وزن‌های مختلف؛

۷. بهترین وزن‌های پیدا شده؛

۸. توضیح درباره غیرقابل‌تفکیک بودن کامل داده‌ها؛

۹. پیش‌بینی چهار نمونه آزمون؛

۱۰. محاسبه خطای آزمون؛

۱۱. پاسخ کوتاه به سؤال‌های تحلیلی تمرین؛

۱۲. کد مرتب و قابل اجرا از ابتدا تا انتها.

۱۵. نکات مهم در ارزیابی

نمره تمرین فقط بر اساس «کمترین خطا» تعیین نمی‌شود. موارد زیر نیز مهم هستند:

- درست بودن پیاده‌سازی تابع تصمیم؛
- درست بودن محاسبه خطا؛
- درست بودن رسم خط تصمیم؛
- نمایش مناسب داده‌ها؛
- توضیح منطقی درباره نتیجه‌ها؛
- مقایسه آموزش و آزمون؛
- خوانایی و سازمان‌دهی نوت‌بوک؛
- اجرای بدون خطای همه سلول‌ها.

۱۶. نکته درباره جداپذیری داده‌ها

این داده‌ها عمداً طوری انتخاب شده‌اند که یک خط نتواند دو گروه را به‌طور کامل از یکدیگر جدا کند. بنابراین انتظار نداریم با انتخاب w_0, w_1, w_2 مناسب، خطای آموزش به صفر برسد.

دانشجو باید این موضوع را از روی آزمایش‌های خود مشاهده و در گزارش توضیح دهد، نه اینکه صرفاً نتیجه را اعلام کند.

۱۷. محل اجرای نوت‌بوک و نحوه تحویل لینک

گزینه پیشنهادی برای تحویل، استفاده از **GitHub** است. GitHub طبق سیاست رسمی فعلی خود اعلام کرده است که برای توسعه‌دهندگان مقیم ایران مجوز ارائه خدمات ابری دارد و سرویس‌های رایگان آن نیز در ایران قابل استفاده‌اند. GitHub برای نگهداری فایل ipynb. و ارائه لینک مستقیم بسیار مناسب است.

دانشجو می‌تواند:

۱. یک مخزن عمومی در GitHub ایجاد کند؛

۲. فایل ipynb. را در آن قرار دهد؛

۳. نوت‌بوک را اجرا و خروجی نمودارها و جدول‌ها را ذخیره کند؛

۴. لینک مخزن یا لینک مستقیم فایل نوت‌بوک را برای استاد ارسال کند.

آدرس:

توجه: سرویس‌هایی مانند Colab Google از نظر فنی برای این نوع تمرین بسیار مناسب‌اند، اما دسترسی از ایران ممکن است به‌دلیل محدودیت‌های منطقه‌ای پایدار نباشد؛ بنابراین برای شرط «قابل دسترسی برای دانشجویان داخل ایران»، GitHub گزینه مطمئن‌تری برای محل تحویل فایل است.

۱۸. پرسش پایانی

در پایان نوت‌بوک، در یک سلول Markdown در حدود ۵ تا ۱۰ خط به این پرسش پاسخ دهید:

> **اگر داده‌های آموزشی کاملاً خطی جداپذیر نباشند، آیا استفاده از یک دسته‌بند خطی همچنان منطقی است؟ چه زمانی باید به سراغ مدل یا مرز تصمیم پیچیده‌تری رفت؟**

هدف این سؤال، سنجش درک شما از محدودیت مدل خطی است؛ نه صرفاً پیدا کردن یک عدد کوچک برای خطای آموزش.